

Vietnamese Social Media Lexical Normalization using BARTpho with Weakly-Supervised Data Augmentation

1. Ý tưởng đề tài

Đề tài xây dựng một hệ thống sử dụng **Transformer để chuẩn hóa văn bản tiếng Việt không chuẩn trên mạng xã hội** thành dạng tiếng Việt chuẩn hơn.

Ví dụ:

mik ko bt hnay đi hc ko
→ mình không biết hôm nay đi học không

mún đky môn này
→ muốn đăng ký môn này

sp đẹp, giao cx nhanh
→ sản phẩm đẹp, giao cũng nhanh

Bài toán được gọi là **Lexical Normalization**: chuyển các **Non-Standard Words (NSWs)** như từ viết tắt, teencode, lỗi chính tả, từ thiếu dấu hoặc các cách viết đặc trưng của mạng xã hội về dạng chuẩn tương ứng. Lexical normalization có thể gồm ánh xạ **1→1, 1→n hoặc n→1**, ví dụ ko → không hay mng → mọi người.

Đây là một bài toán NLP phù hợp với mục **“Other NLP tasks”** của đề. Project đáp ứng hai yêu cầu chính: fine-tune một Transformer trên dataset, đánh giá model, sau đó sử dụng trained model trong một web application.

Phạm vi

Project tập trung vào:

- từ viết tắt: ko, bt, mng ;
- teencode/slang: mik, mún, khum ;
- lỗi chính tả phổ biến;
- từ hoặc câu thiếu dấu;
- các biến thể từ vựng thường gặp trên mạng xã hội.

Project **không hướng đến sửa toàn bộ ngữ pháp hoặc viết lại văn phong**, mà chỉ tập trung vào lexical normalization.

2. Dữ liệu

Đây là phần quan trọng nhất của project. Nhóm sẽ sử dụng **hai nguồn dữ liệu**, gồm dữ liệu chuẩn có nhãn và dữ liệu mạng xã hội chưa có nhãn.

2.1. ViLexNorm – Gold labeled data

Nguồn dữ liệu chính là **ViLexNorm – Vietnamese Lexical Normalization Corpus**, công bố tại EACL 2024.

ViLexNorm gồm **10.467 cặp câu được con người annotate**, lấy từ các bình luận công khai trên mạng xã hội Việt Nam. Mỗi sample gồm:

Original:
Câu tiếng Việt mạng xã hội

Normalized:
Câu sau khi được chuẩn hóa

Ví dụ về cấu trúc:

Original: hôm nay t ko đi học
Normalized: hôm nay tao không đi học

ViLexNorm được chia thành **train / development / test theo tỷ lệ 8:1:1**. Sau preprocessing trong nghiên cứu weak-supervision tiếp theo còn 10.463 entries; khoảng **17% từ trong các split cần normalization**.

Đây sẽ là **gold data**, tức dữ liệu đáng tin cậy nhất của project.

Cách sử dụng:

ViLexNorm Train
→ huấn luyện model

ViLexNorm Dev
→ chọn model / hyperparameter

ViLexNorm Test
→ đánh giá cuối cùng

Test set sẽ được giữ riêng và **không sử dụng để huấn luyện hoặc tạo pseudo-label**.

2.2. ViSoLex – Additional unlabeled social-media data

ViSoLex là hệ thống lexical normalization được công bố tại COLING 2025. Một điểm quan trọng trong hướng tiếp cận của ViSoLex là sử dụng **cả labeled data và lượng lớn unlabeled Vietnamese social-media data**, thay vì chỉ phụ thuộc vào khoảng 10 nghìn câu được annotate thủ công.

Nguồn unlabeled data được tổng hợp từ năm dataset tiếng Việt:

Dataset	Nội dung gốc
ViHSD	Hate speech
UIT-VSMEC	Emotion recognition
ViHOS	Hate/offensive span
ViSpamReviews	Product reviews/spam
UIT-ViSFD	Sentiment & aspect analysis

Các dataset này vốn không được xây dựng cho lexical normalization, nhưng chứa lượng lớn văn bản tiếng Việt thực tế từ mạng xã hội và review.

Sau preprocessing, nghiên cứu tạo được:

121.087 câu unlabeled

với các trường như nguồn dataset, split gốc, original sentence và tokenized input.

Điểm cần nhấn mạnh:

121.087 câu này không phải 121.087 cặp `noisy → normalized` **do con người annotate.**

Chúng là **unlabeled social-media text**. Vì vậy không thể đưa thẳng chúng vào supervised training như ViLexNorm. Project sẽ sử dụng **pseudo-labeling / weakly-supervised data augmentation** để tận dụng phần dữ liệu này.

3. Mô hình

3.1. BARTpho

Model chính được chọn là **BARTpho**, một pretrained Transformer sequence-to-sequence dành riêng cho tiếng Việt.

BARTpho dựa trên kiến trúc BART và gồm:

```
Input
↓
Transformer Encoder
↓
Context Representation
↓
Transformer Decoder
↓
Generated Output
```

Trong quá trình pretraining, BART-style models nhận văn bản đã bị làm nhiễu và học cách **khôi phục lại chuỗi ban đầu**. Vì vậy kiến trúc này phù hợp tự nhiên với lexical normalization:

Pretraining:

```
Corrupted text
→ BART
→ Original text
```

Project:

```
Noisy social-media text
→ BARTpho
→ Normalized Vietnamese
```

BARTpho được công bố với hai phiên bản là **BARTpho-word** và **BARTpho-syllable**, và được thiết kế cho các generative NLP tasks tiếng Việt.

3.2. BARTpho-syllable

Project chọn **BARTpho-syllable** làm model chính.

Khác với BARTpho-word, BARTpho-syllable không phụ thuộc vào bước Vietnamese word segmentation trước khi đưa câu vào model.

Điều này đặc biệt phù hợp với social-media text:

```
mik ko bt hnay đi hc ko
```

vì những từ như:

```
mik
ko
bt
```

hnay
hc

vốn không phải dạng tiếng Việt chuẩn, nên một word segmenter chạy trước model có thể xử lý chúng không chính xác.

Quan trọng hơn, trong benchmark ViLexNorm, **BARTpho-syllable** là hệ thống đạt kết quả tốt nhất, với ERR 57.74%.

Một ưu điểm khác của encoder-decoder architecture là model không yêu cầu số token output giống input:

đky
↓
đăng ký

Vì vậy BARTpho phù hợp hơn cho formulation sequence-to-sequence của bài toán.

4. Phương pháp đề xuất

Thay vì chỉ fine-tune BARTpho trên ViLexNorm giống nghiên cứu trước, project sẽ thực hiện **hai thí nghiệm** để xem dữ liệu bổ sung từ ViSoLex có giúp model tốt hơn hay không.

Experiment 1 – Gold Data Baseline

Fine-tune BARTpho-syllable chỉ bằng:

ViLexNorm Train
↓
BARTpho-syllable
↓
Model A

Model A đóng vai trò **supervised baseline**.

Experiment 2 – Gold + Pseudo-labeled Data

Đầu tiên sử dụng Model A để normalize unlabeled social-media text:

ViSoLex Unlabeled Data
↓
Model A

↓
Pseudo-normalized sentences

Ví dụ:

Original:
mik thấy sp này cx oke

Pseudo target:
mình thấy sản phẩm này cũng oke

Các prediction có độ tin cậy quá thấp sẽ được loại bỏ. Chỉ giữ một subset pseudo-label có chất lượng tương đối tốt.

Sau đó:

ViLexNorm Gold Train
+
Filtered Pseudo-labeled Data
↓
BARTpho-syllable
↓
Model B

Như vậy Model B được tiếp xúc với lượng social-media text đa dạng hơn.

Ý tưởng này đơn giản hóa phương pháp của ViSoLex. ViSoLex đầy đủ sử dụng một framework phức tạp hơn gồm **Student model, Rule Attention Network Teacher, weak supervision rules và multitask learning**.

Project **không reproduce toàn bộ ViSoLex**, vì điều đó vượt quá phạm vi cần thiết của môn học.

5. Thiết kế thí nghiệm

Hai model được đánh giá trên **cùng một ViLexNorm Test set**:

Model	Training Data
Model A	ViLexNorm gold data
Model B	ViLexNorm gold + filtered pseudo data

Câu hỏi nghiên cứu chính là:

Liệu bổ sung một lượng lớn weakly/pseudo-labeled Vietnamese social-media data có cải thiện BARTpho lexical normalization so với chỉ sử dụng dữ liệu human-annotated hay không?

Có thể đo mức cải thiện:

$$\Delta = Performance_{Gold+Pseudo} - Performance_{Gold}$$

Nếu Model B tốt hơn, project cho thấy additional social-media data giúp model generalize tốt hơn.

Nếu Model B không tốt hơn, đây vẫn là một kết quả có ý nghĩa: nhóm có thể phân tích tác động của **noise trong pseudo-labels**.

6. Evaluation

Metric chính sẽ gồm:

- **ERR – Error Reduction Rate**
- **Precision**
- **Recall**
- **F1-score**

ViLexNorm sử dụng ERR với **Leave-As-Is (LAI)** làm baseline. Hệ thống tốt nhất trong paper đạt ERR 57.74%.

Ngoài kết quả tổng thể, nhóm sẽ thực hiện **error analysis**, ví dụ:

```
Correct:
ko → không

Missed normalization:
khum → khum

Wrong normalization:
mún → muốn ✓
mún → muốn? prediction khác ✗

Over-normalization:
model thay đổi một từ vốn đã đúng
```

Phần này giúp giải thích model tốt hoặc kém ở loại NSW nào, thay vì chỉ báo cáo một con số.

7. Web Application

Sau khi so sánh Model A và Model B, model có kết quả tốt nhất sẽ được deploy thành web application bằng **Gradio hoặc Streamlit**.

Luồng hoạt động:

User nhập:

mik ko bt hnay đi hc ko

↓
Normalize
↓

mình không biết hôm nay đi học không

Web app gồm:

- ô nhập văn bản;
- nút **Normalize**;
- output normalized text;
- hiển thị các từ đã được thay đổi nếu có thể.

Ví dụ:

mik → mình
ko → không
bt → biết
hnay → hôm nay
hc → học

Web sử dụng **checkpoint do chính nhóm fine-tune**, đáp ứng yêu cầu ứng dụng web trong đề bài.

8. Tóm tắt đề tài

Tên đề tài:

Vietnamese Social Media Lexical Normalization using BARTpho with Weakly-Supervised Data Augmentation

Bài toán:

Chuẩn hóa tiếng Việt không chuẩn trên mạng xã hội.

Model:

BARTpho-syllable – pretrained encoder-decoder Transformer cho tiếng Việt.

Gold dataset:

ViLexNorm – 10.467 human-annotated sentence pairs.

Additional dataset:

121.087 unlabeled Vietnamese social-media sentences được tổng hợp trong hướng nghiên cứu ViSoLex từ 5 public datasets.

Phương pháp:

```
Experiment 1
ViLexNorm
→ BARTpho
→ Model A

Experiment 2
ViLexNorm + filtered pseudo-labeled ViSoLex data
→ BARTpho
→ Model B

Model A vs Model B
→ Same ViLexNorm Test Set
→ ERR / Precision / Recall / F1
```

Đầu ra cuối cùng:

1. Dataset preprocessing pipeline.
2. BARTpho model đã fine-tune.
3. So sánh gold-only và gold + pseudo-data.
4. Evaluation + error analysis.
5. Web application cho Vietnamese Social Media Text Normalization.

Hướng này vẫn giữ project **đủ gọn để triển khai**, nhưng tốt hơn việc đơn thuần reproduce ViLexNorm: nhóm có một câu hỏi thực nghiệm rõ ràng về **ảnh hưởng của additional weakly supervised data**, đồng thời vẫn đáp ứng đầy đủ yêu cầu train/fine-tune, evaluation và web application của final project.